Detekcija karcinoma dojke

Kasandra Galić, BI58/2019, kasandra.brandic.office@gmail.com

I. Uvod

Karcinom dojke je jedan od najčešćih tipova karcinoma koji pogađa žene širom sveta. Rano otkrivanje i blagovremeno lečenje karcinoma dojke značajno povećavaju šanse za preživljavanje i smanjuju rizik od komplikacija. Stoga je razvoj preciznog i efikasnog algoritma za otkrivanje karcinoma dojke od ključane važnosti za poboljšanje ishoda pacijenata. Algoritmi mašinskog učenja pokazali su veliko obećanje u različitim medicinskim primenama, uključujući otkrivanje karcinoma dojke. U ovom projektu, cilj nam je da istražimo performanse različitih algoritama mašinskog učenja u klasifikaciji karcinoma dojke na osnovu podataka o pacijentima kao što su starost, BMI i rezultati analize krvi. Analiziraćemo bazu podataka za otkrivanje karcinoma dojke koja sadrži informacije o 116 pacijenatu, kako bismo razvili i uporedili performanse različitih algoritama.

II. Baza podataka

U bazi podataka postoji 116 uzorak i 10 obeležja. Baza podataka se sastoji od sledećih atributa:

- Age: starost pacijenta u godinama
- BMI: indeks telesne mase pacijenta, izračunat kao težina u kilogramima podeljena sa visinom u metrima na kvadrat
- Glucose: nivo glukoze našte kod pacijenata u mg/dl
- Insulin: nivo insulina našte kod pacijenta u mIU/L
- HOMA: indeks procene homeostatskog modela, izračunata vrednost insulinske rezistencije na osnovu glukoze i nivoa insulina našte
- Leptin: nivo leptina kod pacijenata u ng/ml
- Adiponectin: nivo adiponektina kod pacijenata u µg/ml
- Resistin: nivo rezistina kod pacijenata u µg/ml
- MCP-1: nivo monocitnog hemoatraktantnog proteina-1 pacijenata u pg/dl
- Classification: oznaka klase pacijenata, gde 1 označava da nema karcinoma dojke, a 2 označava da je karcinom dojke prisutan

Skup podataka ne sadrži nedostajuće vrednosti niti duplikate. Slike 1 i 2 prikazuju distibuciju starosti pacijenata u uzorcima. Populacija ispod 30 godina nema karcinom, dok su osobe starosti od 40-50 godina sklonije razvoju karcinoma dojke. Osobe starosti od 70-90 godina imaju vrlo malu šansu za razvoj karcinoma. Dakle, osobe starosti od 40-70 godina imaju visok rizik od razvoja raka dojke.

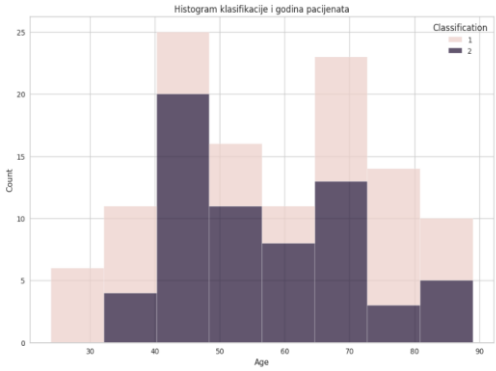

Sl.1. Histogram klasifikacije i godina pacijenata

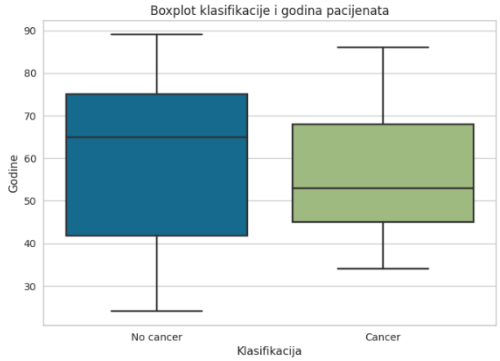

Sl.2. Boxplot klasifikacije i godina pacijenata

Koeficijenti korelacije po parovima obeležja pomoću toplotne mape prikazane na slici 3 pokazuju da glukoza, insulin, HOMA i rezistin imaju pozitivnu korelaciju sa klasifikacijom (tj. oni su važne karakteristike u određivanju da li je karcinom prisutan ili ne). Ostale karakteristike, međutim, nemaju jaku korelaciju sa oznakom klasifikacije, ali mogu igrati važnu ulogu kada su podešene sa odgovarajućim modelima.

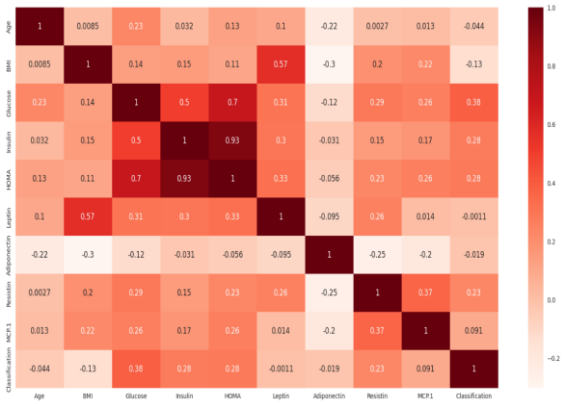

Sl.3.Koeficijenti korelacije pomoću toplotne mape

III. METODOLOGIJA I REZULTATI

Unakrsna validacija se zasniva na principu podele dostupnog skupa uzoraka na M disjunktnih podskupova (u ovom slučaju 10). Proces obuke i testiranja za svaki model se ponavljaju M puta, tako što se u svakoj iteraciji M-1 podskupova koristi za obuku modela, dok se testiranje izvršava na preostalom podskupu. Na ovaj način svaki od uzoraka se više puta koristi za treniranje i samo jednom za testiranje.

Za analizu ove baze podataka korićena su četiri modela.

A. kNN

Metoda kasnog učenja koja podrazumeva odlaganje obrade uzorka za obuku do trenutka kada treba klasifikovati neobeleženi uzorak. Prilikom klasifikacije neobeleženog uzorka, na osnovu odabrane metrike se meri njegova udaljenost od svakog uzorka iz skupa za obuku. U ovom slučaju, tačnost i osetljivost su 0.516, što znači da je model tačno predvideo klasu uzoraka oko 50% vremena. Preciznost i F-mera su nešto niži na 0.490 i 0.487. Ovo pokazuje da model ima visoku stopu lažno pozitivnih rezultata, što znači da neke uzorke karcinoma označava kao nekancerozne.

B. Logistička regresija

Statistički model koji se koristi za predviđanje aposteriorne verovatnoće klasa za dati uzorak, odnosno, predviđanje vrednosti binarne zavisne promenljive. Modeluje verovatnoću binarne ciljne varijable (u ovom slučaju, kancer ili ne-kancer) koristeći logističku funkciju. Tačnost i osetljivost su veći od kNN-a na 0.717 dok su preciznost i F-mera takođe viši na 0.724 i 0.708. Ovo ukazuje da model radi bolje od kNN-a i da ima bolju ravnotežu između istinitih pozitivnih i lažnih pozitivnih rezultata.

C. Metoda slučajne šume

Ansambalsko učenje podrazumeva obuku više jednostavnih modela sa ciljem unapređenja performansi pri rešavanju kompleksnijih problema. Koristi stabla odluke kao jednostavne klasifikatore ili regresore. Pokazao se kao veoma uspešan algoritam i za klasifikacione i za regresione probleme ako je skup podataka za obuku dovoljno velik. Tačnost, preciznost, osetljivost i F-mera za metodu slučajne šume su svi veoma slični modelu Logističke regresije, što ukazuje da radi na sličnom nivou.

D. XGBoost

Napredna verzija Gradient Boosting-a koja koristi kombinaciju slabih modela učenja kako bi kreirala precizniji prediktivni model. Zbog svoje visoke preciznosti i efikasnosti, široko se koristi u takmičenjima iz oblasti nauke o podacima. Model XGBoost ima najveću tačnost, preciznost, osetljivost i F-meru od svih modela, i to redom 0.769, 0.778, 0.770 i 0.768. Ovo ukazuje da je XGBoost najbolji model i da se može koristiti za tačne predikcije na ovom skupu podataka o karcinomu dojke.

IV. REDUKCIJA DIMENZIONALNOSTI

Koristeći PCA tehniku redukcije dimenzialnosti, karakteristike su smanjene sa 9 na 5, a koristeći unakrsnu validaciju ponovo smo evaluirali ove modele. Za kNN tačnost, preciznost, osetljivost i F-mera su se smanjili. To može biti posledica gubitka informacija uzorkovanih redukcijom dimenzialnosti, što je moglo smanjiti efikasnost kNN algoritma u identifikovanju uzoraka i pravljenju tačnih predikcija. S druge strane, performanse logističke regresije i slučajne šume su ostale relativno slične, sa manjim promenama u tačnosti, preciznosti, osetljivosti i F-meri. To može ukazivati na to da smanjeni skup karakteristika još uvek sadrži dovoljno relevantnih informacija da se ovi modeli treniraju efikasno. Za XGBoost tačnost se smanjila, dok su se preciznost, osetljivost i F-mera poboljšali. To ukazuje da je smanjeni skup karakteristika pomogao modelu da bolje identifikuje uzorke i pravi tačne predikcije. Uopšteno, performanse modela nakon redukcije dimenzionalnosti PCA su pomešane. Iako su neki modeli mogli biti poboljšani, drugi su mogli da izgube na performansama zbog gubitka informacija uzrokovanih smanjenjem skupa karakteristika. Stoga je važno pažljivo proceniti uticaj PCA na performanse modela pre donošenja zaključaka. U Tabeli 1 i Tabeli 2 možemo videti podatke svih modela bez i sa PCA.

Tabela 1: Bez PCA najbolji model

BEZ PCA				
	Tačnost	***Preciznost***	***Osetljivost***	***F-mera***
KNN	51,6	49,0	51,6	48,7
LR	71,2	72,4	71,4	70,8
RF	71,8	72,1	71,8	71,4
XGB	76,9	77,8	76,9	76,7

Tabela 2: Sa PCA najbolji model

PCA				
	Tačnost	***Preciznost***	***Osetljivost***	***F-mera***
KNN	49,0	46,7	49,0	46,6
LR	76,9	77,6	76,9	76,0
RF	71,5	73,6	71,5	70,7
XGB	64,7	68,4	64,7	63,8

Sledeći rezultati pokazuju matricu konfuzije i izveštaj klasifikacije za najbolje modele sa njihovim najboljim performansama sa PCA i bez PCA. Slike 4a i 4b pokazuju najbolju podelu za logističku regresiju primenom PCA. Broj pogrešno klasifikovanih je manji u poređenju sa drugim modelima, stoga je najbolji izbor kada se primenjuje sa mogućnošću redukcije dimenzionalnosti.

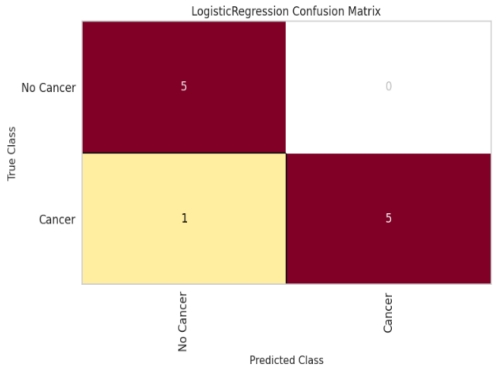

Sl.4a. Matrica konfuzije za logističku regresiju

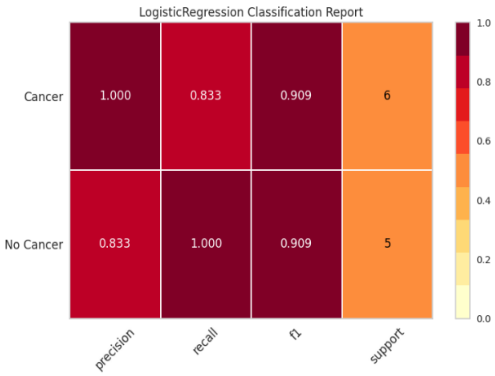

Sl. 4b. Izveštaj o klasifikaciji za logističku regresiju

Međutim isti rezultati mogu se postići za istu podelu bez upotrebe tehnike redukcije dimenzionalnosti. Metrika rezultata ukazuje na to da XGBoost uspeva da izvuče najviše iz karakteristika koje nemaju sniženu korelaciju sa klasifikacijom, može se videti na slici 5a i 5b.

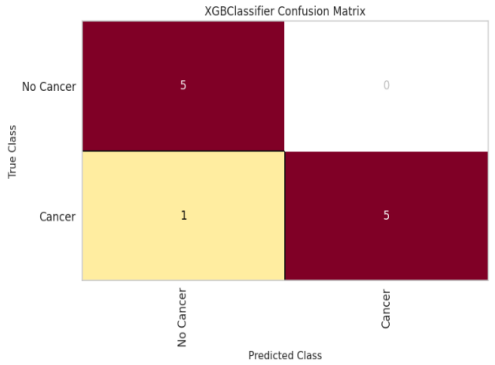

Sl. 5a. Matrica konfuzije za XGB klasifikator

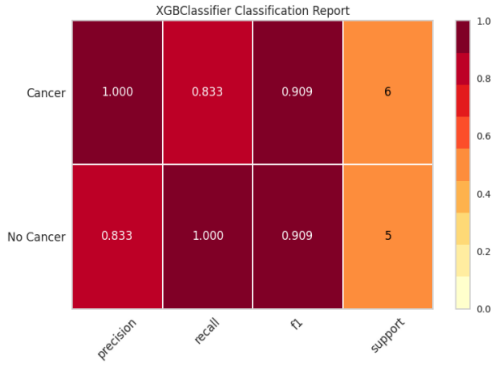

Sl. 5b. Izveštaj o klasifikaciji za XGB klasifikator

V. Zaključak

Na osnovu rezultata, može se zaključiti da upotreba PCA za redukciju dimenzionalnosti skupa podataka ne vodi uvek poboljšanju performansi modela. U ovom slučaju, za kNN i XGBoost, performanse modela su se smanjile nakon redukcije dimenzionalnosti sa PCA, dok su za logističku regresiju i metod slučajne šume performanse bile nepromenjene ili poboljšane. Kada se podaci povećaju upotreba PCA za redukciju dimenzionalnosti može biti korisnija, jer pomaže u smanjenju vremena računanja i zahtevnosti za memorijom modela što je posebno važno za velike skupove podataka. Međutim, treba napomenuti da optimalni broj glavnih komponenti koje treba zadržati može varirati u zavisnosti od specifičnog skupa podataka i problema koji se rešava. Zbog toga je važno sprovesti eksperimente i izabrati najbolji pristup na osnovu metrika performansi i sl.

VI. Reference

[1] Nosek, T., Brkljač, B., Despotović, D., Sečujski, M., Lončar-Turukalo, T. Praktikum iz mašinskog učenja. 2020.

[2]https://xgboost.readthedocs.io/en/stable/python/python_api.html